



Prophet

**Docente: Felipe Palomino & Diego Agudelo
& Daniel Osorio**



Photo: Felipe Palomino / Univalle

Prophet-Based Medium and Long-Term Electricity Load Forecasting Research



Introducción

- Objetivo Nacional de Sostenibilidad
- Desafíos en la Predicción de Carga
- Métodos de Predicción Tradicionales y Uso de Aprendizaje Automático
- Aplicación y ventajas del Modelo Prophet



Métodos y análisis

- Se utilizan datos de carga eléctrica de una región específica desde 2009 hasta 2014 con un muestreo diario.
- Impacto de los Días Festivos y diferencias en la duración de los Días Festivos
- Se implementa el modelo Prophet utilizando una descomposición en tendencia, estacionalidad y días festivos, modelando cada uno por separado para lograr la predicción.
- Se utilizan el MAPE y el RMSE para evaluar la precisión y el ajuste del modelo de predicción y se compararon con métodos tradicionales.



Resultados

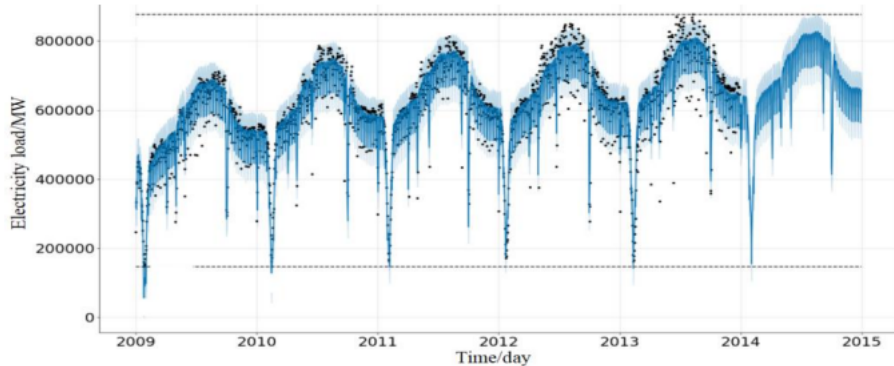


Figure 6. Prophet fitting effect and prediction results.



Definiciones

La descomposición aditiva de Hodrick-Prescott separa una serie de tiempo y_t en una tendencia τ_t y un componente cíclico c_t :

$$y_t = \tau_t + c_t + e_t$$

La descomposición multiplicativa de Hodrick-Prescott expresa una serie de tiempo y_t como el producto de una tendencia τ_t y un componente cíclico c_t :

$$y_t = \tau_t \cdot c_t \cdot e_t$$



Prophet

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (1)$$

Aquí:

- $g(t)$ es la función de tendencia que modela los cambios no periódicos en el valor de la serie temporal.
- $s(t)$ representa los cambios periódicos (por ejemplo, estacionalidad semanal y anual).
- $h(t)$ representa los efectos de los días festivos que ocurren en horarios potencialmente irregulares durante uno o más días.
- El término de error ϵ_t representa cualquier cambio que no esté contemplado por el modelo.



Prophet

La componente estacional se modela comúnmente usando el modelo de crecimiento logístico, que en su forma más básica es

$$g(t) = \frac{C}{1 + \exp(-k(t - m))}, \quad (2)$$

donde

- C es la capacidad de carga
- k es la tasa de crecimiento
- m es un parámetro de desplazamiento.



Prophet

Incorporamos cambios de tendencia en el modelo de crecimiento definiendo explícitamente puntos de cambio donde se permite que la tasa de crecimiento cambie. Supongamos que hay S puntos de cambio en los tiempos s_j , $j = 1, \dots, S$. Definimos un vector de ajustes de tasa $\delta \in \mathbb{R}^S$, donde δ_j es el cambio en la tasa que ocurre en el tiempo s_j . La tasa en cualquier momento t es entonces la tasa base k , más todos los ajustes hasta ese punto: $k + \sum_{j:t > s_j} \delta_j$. Esto se representa de manera más clara definiendo un vector $a(t) \in \{0, 1\}^S$ tal que

$$a_j(t) = \begin{cases} 1, & \text{si } t \geq s_j, \\ 0, & \text{de lo contrario.} \end{cases} \quad (3)$$

La tasa en el tiempo t es entonces $k + a(t)^\top \delta$. Cuando se ajusta la tasa k , el parámetro de desplazamiento m también debe ajustarse para conectar los extremos de los segmentos.



Prophet

La corrección adecuada en el punto de cambio j se calcula fácilmente con la siguiente expresión:

$$\gamma_j = \left(s_j - m - \sum_{l < j} \gamma_l \right) \left(1 - \frac{k + \sum_{l < j} \delta_l}{k + \sum_{l \leq j} \delta_l} \right).$$

(4)

El modelo de crecimiento logístico por tramos es entonces

$$g(t) = \frac{C(t)}{1 + \exp(-(k + a(t)^\top \delta)(t - (m + a(t)^\top \gamma)))}$$

(5) 

Prophet

Para problemas de pronóstico que no muestran un crecimiento saturado, un modelo con una tasa de crecimiento constante por tramos es una opción parsimoniosa y útil. El modelo de tendencia en este caso es:

$$g(t) = (k + a(t)^\top \delta)t + (m + a(t)^\top \gamma),$$

donde:

- k es la tasa de crecimiento
- δ contiene los ajustes de la tasa
- m es el parámetro de desplazamiento
- γ_j se establece en $-s_j \delta_j$



Prophet

Los puntos de cambio s_j pueden ser especificados por el analista usando fechas conocidas de lanzamientos de productos y otros eventos que alteran el crecimiento, o pueden ser seleccionados automáticamente a partir de un conjunto de candidatos. La selección automática se puede realizar de manera natural con la formulación en las ecuaciones anteriores (3) y (4) aplicando un prior escaso sobre δ .



Prophet

A menudo, se especifica un gran número de puntos de cambio (por ejemplo, uno por mes para un historial de varios años) y se usa el prior $\delta_j \sim \text{Laplace}(0, \tau)$. El parámetro τ controla directamente la flexibilidad del modelo para alterar su tasa. Es importante destacar que un prior escaso sobre los ajustes δ no afecta la tasa de crecimiento primaria k , de modo que, a medida que τ tiende a 0, el ajuste se reduce al crecimiento logístico o lineal estándar (no por tramos).



Prophet

$$s(t) = \sum_{n=1}^N \left(a_n \cos \left(\frac{2\pi nt}{P} \right) + b_n \sin \left(\frac{2\pi nt}{P} \right) \right)$$

Donde:

- $s(t)$ es la función de estacionalidad en el tiempo t
- N es el número de términos en la serie de Fourier
- a_n y b_n son coeficientes que determinan la amplitud y la fase de las componentes de la serie de Fourier, respectivamente. Estos coeficientes deben ser estimados a partir de los datos.



Prophet

$$s(t) = X(t)\beta$$

Donde:

- $s(t)$ es la función de estacionalidad en el tiempo t
- $X(t)$ es la matriz de diseño que contiene las características de la estacionalidad en el tiempo t
- β es el vector de parámetros que determinan la relación entre las características de la estacionalidad y la función de estacionalidad
- $\beta \sim \text{Normal}(0, \sigma^2)$



Prophet

Para modelar los efectos de los días festivos, asignamos a cada día festivo i un parámetro κ_i , que representa el cambio correspondiente en el pronóstico. Esto se hace de manera similar a la estacionalidad, generando una matriz de regresores:

$$Z(t) = [1(t \in D_1), \dots, 1(t \in D_L)]$$

Donde D_i es el conjunto de días del día festivo i , y así:

$$h(t) = Z(t)\kappa$$

Al igual que con la estacionalidad, se utiliza un prior $\kappa \sim \text{Normal}(0, \nu^2)$.



Prophet

```
model {  
  // Priors  
  k ~ normal(0, 5);  
  m ~ normal(0, 5);  
  epsilon ~ normal(0, 0.5);  
  delta ~ double_exponential(0, tau);  
  beta ~ normal(0, sigma);  
  
  // Logistic likelihood  
  y ~ normal(C ./ (1 + exp(-(k + A * delta) .* (t - (m + A * gamma)))) +  
            X * beta, epsilon);  
  
  // Linear likelihood  
  y ~ normal((k + A * delta) .* t + (m + A * gamma) + X * beta, sigma);  
}
```



Datos Replicación

Table: Definición variables

Variable	Descripción
Visits to a website	Visitas a un sitio web
Black Friday	viernes negros
Christmas	Festividades de fin de año
Easter	Pascua



Ejercicio aplicado